

---

# ANALISIS HARGA BITCOIN MENGGUNAKAN ARTIFICIAL NEURAL NETWORK

---

Tegar Satrio Pamungkas, Otniel Anugrah Ntoy, Johannes Bagus Pramindra, Vincentius Pramudya Ananta,  
Yohanes Rio Dewantoro

<sup>1</sup>Jurusan Matematika, Fakultas Sains dan Matematika, Universitas Kristen Satya Wacana, Salatiga, Jawa Tengah 50711

[662022001@student.uksw.edu](mailto:662022001@student.uksw.edu), [662022013@student.uksw.edu](mailto:662022013@student.uksw.edu), [662023002@student.uksw.edu](mailto:662023002@student.uksw.edu),  
[662023004@student.uksw.edu](mailto:662023004@student.uksw.edu), [662023009@student.uksw.edu](mailto:662023009@student.uksw.edu)

## ABSTRAK

Penelitian ini bertujuan untuk memprediksi harga penutupan (*Close*) Bitcoin menggunakan pendekatan *Artificial Neural Network* (ANN) dengan konfigurasi parameter optimal. Data historis harga Bitcoin dari April 2023 hingga Juni 2025 digunakan sebagai basis pelatihan dan pengujian model. Dataset terdiri dari lima variabel input, yaitu *Open*, *High*, *Low*, *Close*, dan *Market Cap*, dengan target output berupa harga *Close* pada hari berikutnya. Model ANN yang dibangun memiliki satu *hidden layer* dengan 12 neuron, dan dilatih menggunakan algoritma *Levenberg-Marquardt* selama 80 epoch.

Evaluasi kinerja model dilakukan dengan metrik *MAPE*, *RMSE*, *MAE*, dan *R-Squared* ( $R^2$ ). Hasil pengujian menunjukkan bahwa model mampu memprediksi harga dengan akurasi tinggi, ditunjukkan oleh nilai *MAPE* sebesar 1,7859%, *RMSE* sebesar 2303,4078, *MAE* sebesar 1658,6268, dan  $R^2$  sebesar 0,9398. Sebagian besar prediksi (94,94%) memiliki tingkat kesalahan di bawah ambang batas 5%. Selain evaluasi kuantitatif, analisis visual terhadap grafik prediksi menunjukkan bahwa model dapat menangkap pola pergerakan harga dengan baik, tanpa indikasi *overfitting* maupun *underfitting*. Temuan ini menunjukkan bahwa ANN mampu berfungsi sebagai alat bantu prediktif yang andal dalam konteks pasar kripto yang volatil.

**Kata kunci:** *Bitcoin; Artificial Neural Network; Prediksi Harga;*

## PENDAHULUAN

*Cryptocurrency*, khususnya Bitcoin, telah menjadi bagian penting dalam perkembangan sistem keuangan digital global karena sifatnya yang terdesentralisasi dan potensi keuntungan tinggi. Namun, tingginya volatilitas harga menjadikan Bitcoin sebagai instrumen investasi yang penuh risiko dan sulit diprediksi. Oleh karena itu, pendekatan berbasis kecerdasan buatan seperti *Artificial Neural Network* (ANN) telah banyak digunakan untuk memodelkan harga Bitcoin berdasarkan pola historis yang kompleks (Muhmmad Sahi, 2023; Sovia et al., 2019). ANN mampu mengenali hubungan non-linear dalam data dan memberikan prediksi yang dapat membantu investor dalam mengambil keputusan yang lebih informatif (Yiying & Yeze, 2019).

Penelitian sebelumnya menunjukkan bahwa ANN cukup efektif dalam menangani data pasar kripto, baik untuk prediksi *return* maupun klasifikasi sentimen. Nakano et al., (2018) membuktikan bahwa ANN dengan arsitektur *deep learning* dapat mengungguli strategi *buy-and-hold* dalam *trading intraday* Bitcoin, bahkan pada saat harga mengalami penurunan tajam. Sementara itu, Tosunoğlu et al., (2023) menambahkan dimensi waktu seperti hari dalam seminggu dan menemukan adanya anomali mingguan pada Bitcoin, menunjukkan potensi prediksi yang lebih dalam. Dalam konteks evaluasi struktur ANN, Muhmmad Sahi, (2023) menunjukkan bahwa penambahan jumlah *hidden layer* secara signifikan meningkatkan akurasi prediksi hingga hampir 99,97%.

Namun, masih terdapat tantangan pada efisiensi dan kestabilan pelatihan model ANN, khususnya dalam menemukan parameter optimal. Nayak et al., (2021) mengatasi hal ini dengan mengusulkan model RA + ANN yang terbukti memiliki performa lebih baik dibanding metode ANN konvensional. Selain itu, penelitian oleh Natzir & Jatiprasetya, (2025) membandingkan performa LSTM dan GRU untuk prediksi harga XLM, dan menemukan bahwa model GRU yang lebih ringan dan sederhana dapat memberikan akurasi lebih tinggi. Di sisi lain, Muh. Isbar Pratama & Lismayani, (2023) menerapkan LSTM untuk menganalisis sentimen Twitter terhadap Bitcoin, membuktikan bahwa ANN juga dapat digunakan dalam konteks analisis sosial untuk memperkaya model prediksi harga.

Penelitian ini bertujuan untuk mengembangkan dan mengevaluasi model prediksi harga Bitcoin berbasis Artificial Neural Network dengan pendekatan konfigurasi optimal. Model akan dianalisis berdasarkan parameter seperti jumlah *epoch*, struktur jaringan, dan *learning rate*, serta dievaluasi menggunakan metrik MSE, MAE, RMSE, dan  $R^2$  (Fegiyanto et al., 2024). Tidak seperti penelitian sebelumnya yang fokus pada algoritma alternatif atau aset kripto lain seperti *Ethereum* dan *Ripple* (Nayak et al., 2021; Yiyang & Yeze, 2019), tulisan ini memberikan fokus khusus pada performa ANN murni dalam konteks Bitcoin. Dengan kontribusi ini, diharapkan hasil penelitian dapat menjadi landasan ilmiah yang berguna bagi investor dan akademisi dalam memahami serta memprediksi dinamika harga Bitcoin secara lebih akurat.

## LANDASAN TEORI

*Artificial Neural Network* (ANN) merupakan salah satu metode dalam kecerdasan buatan yang terinspirasi dari cara kerja sistem saraf biologis manusia. ANN digunakan secara luas untuk berbagai tugas prediksi dan klasifikasi karena kemampuannya dalam mengenali pola kompleks dan hubungan non-linear dalam data. ANN terdiri dari tiga komponen utama: lapisan *input*, lapisan tersembunyi (*hidden layer*), dan lapisan *output*. Setiap neuron dalam jaringan saling terhubung dan memiliki bobot yang dioptimalkan selama proses pelatihan.

Dalam konteks pasar keuangan dan *cryptocurrency*, ANN terbukti efektif dalam menangkap pola historis yang kompleks dan fluktuatif. Sovia et al. (2019) menunjukkan bahwa jaringan *backpropagation* mampu memprediksi harga Bitcoin dengan akurasi yang cukup tinggi. Nakano et al. (2018) juga membuktikan bahwa arsitektur *deep learning* pada ANN dapat mengungguli strategi investasi konvensional seperti *buy-and-hold*, bahkan dalam kondisi pasar yang mengalami penurunan.

ANN memiliki keunggulan dalam memproses banyak fitur sekaligus, seperti harga pembukaan (*open*), harga tertinggi (*high*), harga terendah (*low*), harga penutupan (*close*), serta kapitalisasi pasar (*market cap*), yang semuanya dapat digunakan sebagai variabel *input* untuk memprediksi harga penutupan berikutnya. Model ini juga dapat disesuaikan dengan berbagai parameter seperti jumlah neuron tersembunyi, fungsi aktivasi, algoritma pelatihan, dan jumlah *epoch* agar mencapai performa terbaik.

Struktur ANN yang umum digunakan dalam prediksi waktu (*time series prediction*) adalah jaringan *feedforward* dengan satu atau lebih *hidden layer*. Peningkatan jumlah *hidden layer* dan neuron dapat meningkatkan kapasitas representasi model, namun berisiko menyebabkan *overfitting* jika tidak diimbangi dengan pengaturan validasi yang tepat (Muhmmad Sahi, 2023).

Beberapa parameter penting dalam pelatihan ANN meliputi:

- Fungsi aktivasi: menentukan sifat non-linearitas dalam jaringan, seperti *purelin* atau *tansig*.
- Algoritma pelatihan: *trainlm* (*Levenberg-Marquardt*) populer karena cepat konvergen untuk dataset skala kecil-menengah.
- *Learning rate* dan momentum: mempengaruhi kecepatan dan stabilitas konvergensi.
- Jumlah *epoch*: batas maksimum iterasi pelatihan.

Dalam menilai kinerja sebuah model prediktif, pemilihan metrik evaluasi yang sesuai menjadi hal yang sangat penting. Hal ini bertujuan agar hasil prediksi tidak hanya tampak akurat secara umum, tetapi juga selaras dengan karakteristik dan kebutuhan data yang dianalisis. Beberapa metrik evaluasi yang paling sering digunakan dalam berbagai studi meliputi *Mean Absolute Percentage Error* (MAPE), *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE), serta koefisien determinasi (*R-Squared* atau  $R^2$ ).

1. ***Mean Absolute Percentage Error* (MAPE)** adalah sebuah metrik evaluasi yang digunakan untuk mengukur tingkat akurasi suatu model prediktif dengan cara menghitung rata-rata persentase kesalahan absolut antara nilai aktual dan nilai prediksi. MAPE dinyatakan dalam bentuk persentase, sehingga bersifat relatif terhadap skala data, menjadikannya sangat berguna untuk membandingkan performa model di berbagai dataset yang memiliki satuan atau skala berbeda. Secara matematis, MAPE didefinisikan sebagai rata-rata dari nilai absolut selisih antara nilai aktual ( $y_i$ ) dan nilai prediksi ( $\hat{y}_i$ ), yang kemudian dibagi dengan nilai aktual dan dikalikan 100%. Metrik ini memberikan gambaran seberapa besar, secara persentase, prediksi menyimpang dari nilai sebenarnya; semakin rendah nilai

MAPE, semakin baik performa model. Namun, perlu dicatat bahwa MAPE menjadi kurang akurat apabila terdapat nilai aktual yang mendekati nol, karena dapat menghasilkan nilai *error* yang sangat besar atau tidak terdefinisi.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$$

Di mana:

- $y_i$  adalah nilai aktual ke- $i$ ,
- $\hat{y}_i$  adalah nilai prediksi ke- $i$ ,
- $n$  adalah jumlah total data pada pengujian.

2. **Root Mean Squared Error (RMSE)** adalah metrik evaluasi yang digunakan untuk mengukur seberapa besar rata-rata kesalahan (*error*) antara nilai prediksi dan nilai aktual dalam sebuah model prediktif, dengan memberikan bobot lebih besar terhadap kesalahan yang besar. RMSE dihitung dengan mengkuadratkan selisih antara setiap nilai aktual ( $y_i$ ) dan nilai prediksi ( $\hat{y}_i$ ), menghitung rata-ratanya, lalu mengambil akar kuadrat dari hasil tersebut. Karena proses pengkuadratan, RMSE sangat sensitif terhadap *outlier* atau kesalahan besar, sehingga cocok untuk kasus di mana kesalahan besar perlu mendapat penalti lebih. Nilai RMSE dinyatakan dalam satuan yang sama dengan data aslinya (misalnya dolar untuk data harga), yang membuatnya mudah diinterpretasikan secara langsung. Semakin kecil nilai RMSE, semakin baik performa model dalam memprediksi nilai mendekati aktual. Namun, karena RMSE memberikan penalti yang tinggi terhadap kesalahan besar, nilai ini bisa tampak tinggi jika data memiliki fluktuasi atau *noise* yang besar.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

3. **Mean Absolute Error (MAE)** adalah metrik evaluasi yang digunakan untuk mengukur rata-rata besar kesalahan absolut antara nilai prediksi ( $\hat{y}_i$ ) dan nilai aktual ( $y_i$ ) dalam suatu model prediktif, tanpa memperhatikan arah kesalahan (positif atau negatif). MAE dihitung dengan menjumlahkan semua nilai absolut dari selisih antara prediksi dan aktual, kemudian dibagi dengan jumlah total data. Tidak seperti RMSE yang memberikan penalti lebih besar terhadap kesalahan besar, MAE memperlakukan semua kesalahan secara merata, sehingga lebih tahan terhadap *outlier* dan memberikan estimasi yang lebih realistis terhadap kesalahan rata-rata. Nilai MAE dinyatakan dalam satuan yang sama dengan data asli, misalnya dalam dolar jika digunakan pada prediksi harga, sehingga interpretasinya cukup intuitif. Semakin kecil nilai MAE, semakin baik performa model dalam melakukan prediksi yang mendekati nilai aktual.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

4. **R-Squared ( $R^2$ )**, atau koefisien determinasi, adalah metrik evaluasi yang digunakan untuk mengukur seberapa baik suatu model prediktif mampu menjelaskan variabilitas data target terhadap nilai rata-ratanya.  $R^2$  dihitung sebagai selisih antara total variansi data aktual (*Total Sum of Squares*) dengan variansi error prediksi (*Residual Sum of Squares*), yang kemudian dinormalisasi terhadap total variansi. Nilainya berada dalam rentang 0 hingga 1, di mana nilai 1 menunjukkan bahwa model mampu menjelaskan seluruh variasi dalam data secara sempurna, sedangkan nilai 0 berarti model sama sekali tidak mampu menjelaskan variasi dibandingkan dengan menggunakan rata-rata sebagai prediksi. Dalam konteks regresi, semakin tinggi nilai  $R^2$ , maka semakin baik model dalam menangkap pola hubungan antara variabel input dan output. Namun,  $R^2$  tidak dapat mengukur besarnya kesalahan prediksi secara langsung dan dapat memberikan nilai yang tinggi meskipun model

mengalami *overfitting*, sehingga biasanya digunakan bersama metrik lain seperti RMSE atau MAE untuk memberikan gambaran evaluasi yang lebih komprehensif.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

Di mana:

- $SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  : *Residual Sum of Squares* yaitu jumlah kuadrat selisih antara nilai aktual ( $y_i$ ) dan nilai prediksi ( $\hat{y}_i$ ),
- $SS_{tot} = \sum_{i=1}^n (y_i - \bar{y}_i)^2$  : *Total Sum of Squares* yaitu jumlah kuadrat selisih antara nilai aktual ( $y_i$ ) dan rata-rata nilai aktual ( $\bar{y}_i$ ),
- $y_i$  adalah nilai aktual ke- $i$ ,
- $\hat{y}_i$  adalah nilai prediksi ke- $i$ ,
- $\bar{y}_i$  adalah rata rata dari seluruh nilai aktual,
- $n$  adalah jumlah total data pada pengujian.

Dengan interpretasi:

- Jika  $R^2 = 1$ , maka model menjelaskan semua variansi dalam data.
- Jika  $R^2 = 0$ , maka model tidak lebih baik dari rata-rata.
- Jika  $R^2 < 0$ , model lebih buruk dari sekadar menggunakan rata-rata.

## PROSEDUR KERJA

### 1. Pengumpulan Data

Data historis harga Bitcoin diperoleh dari platform [cryptorank.io](https://cryptorank.io) dari bulan April 2023 - Juni 2025 dengan total 791 data. Kemudian data historis diunduh dalam bentuk file Excel (bitcoin-historical-data.xlsx) yang mencakup beberapa variabel:

- *Open*: harga pembukaan
- *High*: harga tertinggi
- *Low*: harga terendah
- *Close*: harga penutupan
- *Market Cap*: kapitalisasi pasar harian

### 2. Pembentukan Dataset

Data yang diperoleh diproses untuk membentuk pasangan input-output:

- *Input (X)* terdiri dari data harga (*Open, High, Low, Close dan Market Cap* pada hari ke- $t$ )
  - *Output (Y)* adalah harga penutupan (*Close*) pada hari ke- $(t+1)$
- Tujuan dari pemodelan ini adalah memprediksi harga *Close* hari berikutnya berdasarkan data historis sebelumnya.

### 3. Normalisasi Data

Data input dan output dinormalisasi ke dalam rentang  $[0, 1]$  menggunakan metode *mapminmax*, untuk meningkatkan efisiensi proses pelatihan dan menghindari dominasi fitur dengan skala besar.

### 4. Pembagian Data

Dataset dibagi menjadi tiga subset:

- 70% data untuk pelatihan (*training*)
- 30% pengujian (*testing*)

Pembagian dilakukan secara manual berdasarkan indeks, untuk menjamin keteraturan urutan waktu (*time-series*).

## 5. Perancangan Jaringan Saraf Tiruan (Artificial Neural Network)

Model jaringan saraf yang digunakan adalah *Feedforward Neural Network* dengan arsitektur sebagai berikut:

- Jumlah input: 5 (*Open, High, Low, Close, Market Cap*)
- Hidden layer: 12 *neuron*
- Output: 1 *neuron* (prediksi *Close*)

Parameter pelatihan yang digunakan:

- Fungsi aktivasi: *purelin* (fungsi linear)
- Algoritma pelatihan: *trainlm* (*Levenberg-Marquardt*)
- *Epoch*: 80
- *Learning rate*: 0.5
- *Momentum*: 0.2

## 6. Pelatihan Jaringan

Model dilatih menggunakan data yang telah dibagi, dengan proses pelatihan berdasarkan parameter yang telah dikonfigurasi.

## 7. Evaluasi Model

Model dievaluasi menggunakan data pengujian. Beberapa metrik evaluasi yang digunakan:

- *MAPE* (*Mean Absolute Percentage Error*)
- *RMSE* (*Root Mean Squared Error*)
- *MAE* (*Mean Absolute Error*)
- *R-squared* (Koefisien Determinasi)

Selain itu, dilakukan analisis prediksi yang dianggap "gagal" jika memiliki kesalahan lebih dari 5%.

## 8. Visualisasi Hasil

Dua grafik ditampilkan:


- Perbandingan antara harga aktual dan harga prediksi
- Grafik persentase *error* terhadap waktu pengamatan

## 9. Prediksi Harga Hari Berikutnya

Untuk memprediksi harga penutupan hari berikutnya:

- Data terbaru diambil dan dinormalisasi
- Diproses oleh model jaringan yang telah dilatih
- Hasil prediksi dinormalisasi balik (denormalisasi)
- Harga penutupan prediktif ditampilkan sebagai hasil akhir

## HASIL DAN DISKUSI GRAFIK DAN PENJELASAN



Gambar 1. Jendela *Neural Network Matlab*

### 1. Arsitektur Jaringan Saraf Tiruan (JST)

Model yang digunakan dalam penelitian ini adalah Jaringan Saraf Tiruan tipe *feedforward* dengan arsitektur 5-12-1, yaitu:


- 5 neuron *input*, masing-masing mewakili fitur: *open*, *high*, *low*, *close*, dan *market cap*.
- 1 *hidden layer* dengan 12 neuron dan fungsi aktivasi *purelin*.
- 1 neuron *output* untuk memprediksi harga *close* pada hari ke-( $t+1$ ).

### 2. Algoritma Pelatihan

- *Index (divideind)* : Menunjukkan bahwa data pelatihan dan pengujian dibagi berdasarkan indeks manual, bukan secara acak.
- *Levenberg-Marquardt (trainlm)* : Algoritma pelatihan yang digunakan adalah *Levenberg-Marquardt*, untuk menjalankan pelatihan jaringan syaraf termasuk forward proses, backward proses, update bobot dan minimasi error
- *Mean Squared Error (mse)* : Fungsi error yang dioptimasi adalah MSE, yaitu rata-rata selisih kuadrat antara prediksi dan target. Nilainya lebih kecil = lebih baik.
- Default : Metode turunan untuk perhitungan *backpropagation* (default MATLAB)

### 3. Progress


- 7 iterations : Proses pelatihan selesai setelah 7 kali iterasi penuh terhadap data pelatihan. Ini berarti jaringan konvergen sangat cepat.
- 00:01 : Pelatihan hanya memakan waktu 1 detik.
- 0.000223 : Nilai MSE terkecil selama pelatihan. Ini menunjukkan akurasi pelatihan sangat tinggi.
- 9.88e-08 : Nilai gradien saat terakhir training. Semakin kecil nilai ini, berarti jaringan sudah mencapai titik minimum error.
- 1.00e-09 : Parameter adaptif dari algoritma Levenberg-Marquardt. Nilai kecil seperti ini menandakan proses optimasi sangat stabil.
- Validation Checks 1 : pelatihan berhenti karena mencapai minimum gradient, bukan karena *overfitting*.



**Gambar 2.** Garis biru yaitu data aktual, Garis merah putus-putus yaitu prediksi

**Gambar 2** menyajikan perbandingan antara data aktual dan hasil prediksi model selama tahap pengujian (*testing*). Grafik ini menggambarkan nilai harga penutupan (*close price*) dalam satuan  $\times 10^4$  terhadap waktu. Berdasarkan grafik tersebut, terlihat bahwa garis prediksi (ditampilkan sebagai garis merah putus-putus) memiliki pola yang sangat menyerupai garis data aktual (berwarna biru). Kesamaan pola ini mengindikasikan bahwa model mampu menangkap tren pergerakan harga dengan cukup baik, baik saat terjadi kenaikan, penurunan, maupun fluktuasi tajam.

Kemiripan antara kurva prediksi dan kurva aktual menunjukkan bahwa model memiliki kemampuan generalisasi yang baik, yaitu kemampuan untuk merepresentasikan pola data yang belum pernah dilihat sebelumnya. Secara visual, selisih antara nilai prediksi dan nilai aktual tampak relatif kecil, yang menandakan bahwa kesalahan prediksi berada dalam batas toleransi yang wajar. Selain itu, kedekatan kedua kurva tersebut mengisyaratkan bahwa model tidak menunjukkan gejala *overfitting* (terlalu menyesuaikan diri dengan data pelatihan) maupun *underfitting* (gagal menangkap pola data secara menyeluruh) pada data uji.



**Gambar 3.** Garis hitam tipis menunjukkan nilai error harian, Garis horizontal merah putus-putus merupakan ambang batas *error* (*threshold*) sebesar 5%

Sebagai pelengkap analisis visual, **Gambar 3** menyajikan grafik persentase kesalahan harian (*error*) antara hasil prediksi dan data aktual selama masa pengujian. Nilai *error* dihitung berdasarkan selisih relatif antara nilai prediksi dan nilai aktual, kemudian dinyatakan dalam bentuk persentase. Grafik ini dilengkapi dengan garis horizontal berwarna merah sebagai batas toleransi kesalahan sebesar 5%, yang berfungsi sebagai ambang batas maksimum *error* yang masih dianggap dapat diterima.

Dari grafik dapat diamati bahwa sebagian besar nilai *error* harian berada di bawah ambang batas toleransi 5%. Kondisi ini menunjukkan bahwa model secara umum memiliki kemampuan prediksi yang akurat dan stabil dari hari ke hari. Stabilitas *error* dalam batas wajar ini mengindikasikan bahwa model mampu mempertahankan performanya secara konsisten dalam memproyeksikan nilai harga penutupan.

Walaupun demikian, terdapat beberapa titik di mana *error* harian melebihi batas 5%, bahkan mencapai lebih dari 8% pada hari-hari tertentu. Kejadian ini bersifat insidental dan tidak terjadi secara terus-menerus, sehingga tidak memengaruhi performa model secara keseluruhan. Lonjakan *error* tersebut kemungkinan besar disebabkan oleh kondisi pasar yang sangat fluktuatif, keberadaan *outlier* pada data aktual, atau kurangnya representasi pola tertentu dalam data pelatihan.

Frekuensi kemunculan *error* tinggi tersebut tergolong rendah dan tidak mengindikasikan pola kesalahan yang sistematis. Hal ini menunjukkan bahwa meskipun model sesekali mengalami penurunan performa, secara umum ia tetap mampu melakukan generalisasi dengan baik terhadap data baru. Dengan demikian, sebaran *error* harian yang relatif kecil dan konsisten menjadi bukti tambahan atas stabilitas dan akurasi model prediktif yang digunakan.

```
=== EVALUASI MODEL (Data Testing) ===  
MAPE : 1.7861 %  
RMSE : 2303.5448  
MAE : 1658.8329  
  
R-Squared (R?): 0.9398  
Jumlah prediksi tidak sesuai (>5% error): 12 dari 237 data  
Prediksi harga Close Bitcoin untuk hari berikutnya adalah: 101350.18
```

**Gambar 4.** Hasil evaluasi model dan *output* harga *Close* Bitcoin hari ke  $t+1$

#### 1. MAPE

Dalam jurnal penelitian ini, nilai MAPE yang dihasilkan adalah 1.79%, yang berarti bahwa secara rata-rata, prediksi model hanya mengalami deviasi sebesar 1.79% dari nilai aktual. Nilai ini tergolong sangat rendah dan menunjukkan bahwa model memiliki tingkat akurasi yang sangat baik secara relatif. Hasil ini merupakan hasil yang sangat baik, karena dalam banyak studi prediksi time series, MAPE < 10% sudah dianggap baik.

#### 2. RMSE

RMSE dinyatakan dalam satuan yang sama dengan target *output* (yaitu harga Bitcoin dalam satuan USD). Dalam penelitian ini, diperoleh nilai RMSE sebesar 2304.0884, yang menunjukkan bahwa rata-rata deviasi prediksi dari nilai aktual berada di kisaran 2304 USD. Meskipun nilai ini tampak besar, namun konteks harga Bitcoin yang sangat fluktuatif dan tinggi (lebih dari 100.000 USD) membuat nilai RMSE ini tergolong rendah secara proporsional.

#### 3. MAE

Hasil evaluasi menunjukkan bahwa MAE sebesar 1660.3785, yang berarti bahwa rata-rata kesalahan prediksi terhadap nilai aktual berada sekitar 1660 USD. MAE bersifat lebih stabil terhadap *outlier* dibandingkan RMSE dan memberikan estimasi kesalahan yang lebih realistis pada sebagian besar data.

#### 4. R-Squared



$R^2$  sebesar 0.9398 menunjukkan bahwa 93.98% variasi harga aktual dapat dijelaskan oleh model ANN, yang mencerminkan kecocokan model yang sangat baik.

5. Hanya terdapat 12 hari (5,1%) dari total 237 hari pengujian yang memiliki *error* lebih dari 5%, yang artinya sebagian besar prediksi berada dalam rentang toleransi kesalahan yang dapat diterima.
6. Prediksi Harga Hari Berikutnya

Berdasarkan input data dari hari terakhir dalam dataset, model ANN menghasilkan prediksi harga penutupan (*Close*) Bitcoin untuk hari berikutnya sebesar USD 101,350.18. Nilai ini mencerminkan estimasi harga berdasarkan pola historis 5 fitur masukan (*Open, High, Low, Close, dan Market Cap*), yang telah dinormalisasi dan diolah oleh model.

## KESIMPULAN

Penelitian ini menunjukkan bahwa Artificial Neural Network (ANN) dapat digunakan secara efektif untuk memprediksi harga penutupan Bitcoin dengan tingkat akurasi yang sangat tinggi. Dengan menggunakan data historis harga Bitcoin dari bulan April 2023 hingga Juni 2025, model dilatih untuk mengenali pola harga berdasarkan lima variabel penting: harga pembukaan (*Open*), harga tertinggi (*High*), harga terendah (*Low*), harga penutupan (*Close*), dan kapitalisasi pasar (*Market Cap*). Jaringan saraf yang digunakan memiliki satu lapisan tersembunyi dengan 12 neuron dan dilatih menggunakan algoritma *Levenberg-Marquardt* selama 80 epoch. Pendekatan ini terbukti cukup efisien dalam menangkap pola-pola fluktuatif yang sangat khas dari pasar kripto.

Dari hasil pengujian, model mampu menghasilkan prediksi dengan tingkat kesalahan yang sangat rendah. Nilai MAPE sebesar 1,79% menunjukkan bahwa rata-rata kesalahan prediksi hanya sekitar 1,79% dari nilai aktual. Begitu pula nilai RMSE sebesar 2304 dan MAE sebesar 1660, meskipun terlihat cukup besar, tetap tergolong rendah jika dibandingkan dengan harga Bitcoin yang sering kali berada di atas 100.000 USD. Visualisasi hasil prediksi menunjukkan bahwa grafik prediksi hampir selalu mengikuti tren grafik harga aktual, baik saat harga naik, turun, maupun saat terjadi fluktuasi tajam. Ini menandakan bahwa model ANN tidak hanya akurat, tetapi juga stabil dan konsisten dalam berbagai kondisi pasar.

Secara keseluruhan, ANN terbukti sebagai alat yang andal dalam memprediksi harga Bitcoin, bahkan dalam pasar yang sangat dinamis dan penuh ketidakpastian seperti kripto. Sebagian besar prediksi model memiliki *error* harian di bawah ambang batas 5%, yang menandakan performa model tetap stabil dari waktu ke waktu. Temuan ini sangat berguna bagi para investor, analis keuangan, maupun peneliti yang ingin memahami pergerakan harga Bitcoin secara lebih terukur. Ke depan, model ini masih bisa ditingkatkan lagi dengan menambahkan variabel lain, menguji arsitektur yang lebih kompleks, atau menggabungkan ANN dengan metode lain seperti LSTM atau GRU untuk mencapai hasil prediksi yang lebih tajam dan responsif terhadap perubahan pasar.

## DAFTAR PUSTAKA

- Sahi, M., Faisal, M., Arif, Y. M., & Crysdian, C. (2023). Analysis of the Use of Artificial Neural Network Models in Predicting Bitcoin Prices. *Applied Information System and Management (AISM)*, 6(2), 91–96. <https://doi.org/10.15408/aism.v6i2.29648>
- Fegiyanto, R., Hermawan, A., & Ardiani, F. (2024). Prediksi Harga Crypto dengan Algoritma Jaringan Saraf Tiruan. *Jurnal Indonesia : Manajemen Informatika Dan Komunikasi*, 5(3), 2265–2275. <https://doi.org/10.35870/jimik.v5i3.728>
- Muh. Isbar Pratama, & Lismayani, A. (2023). Simulasi Pemodelan Matematika Seir Terhadap Pengaruh Sanitasi Pada Kasus Stunting Di Indonesia. *Proximal: Jurnal Penelitian Matematika Dan Pendidikan Matematika*, 6(1), 224–231. <https://doi.org/10.30605/proximal.v6i1.2230>
- Muhmmad Sahi. (2023). Prediksi Harga Cryptocurrency Berdasarkan Model Artificial Neural Network. *Prediksi Harga Cryptocurrency Berdasarkan Model Artificial Neural Network*, 2588–2593. <http://etheses.uin-malang.ac.id/id/eprint/58667>
- Nakano, M., Takahashi, A., & Takahashi, S. (2018). Bitcoin technical trading with artificial neural network. *Physica A: Statistical Mechanics and Its Applications*, 510, 587–609. <https://doi.org/10.1016/j.physa.2018.07.017>
- Natzir, S. M., & Jatiprasetya, H. (2025). Prediksi Harga Cryptocurrency Xlm Menggunakan Metode Deep Learning Lstm Dan Gru. *HOAQ (High Education of Organization Archive Quality) : Jurnal Teknologi Informasi*, 16(1), 49–58. <https://doi.org/10.52972/hoaq.vol16no1.p49-58>
- Nayak, S. K., Nayak, S. C., & Das, S. (2021). Modeling and Forecasting Cryptocurrency Closing Prices with Rao Algorithm-Based Artificial Neural Networks: A Machine Learning Approach. *FinTech*, 1(1), 47–62. <https://doi.org/10.3390/fintech1010004>
- Setiawan, G. I. (2024). *Jurnal Manajemen dan Teknologi Informasi ( JMTI ) ANALYSIS OF CANNY EDGE DETECTION METHOD FOR FACIAL*. 15(2).
- Sovia, R., Yanto, M., Budiman, A., Mayola, L., & Saputra, D. (2019). Backpropagation neural network prediction for cryptocurrency bitcoin prices. *Journal of Physics: Conference Series*, 1339(1). <https://doi.org/10.1088/1742-6596/1339/1/012060>
- Tosunoğlu, N., Abacı, H., Ateş, G., & Saygılı Akkaya, N. (2023). Artificial neural network analysis of the day of the week anomaly in cryptocurrencies. *Financial Innovation*, 9(1). <https://doi.org/10.1186/s40854-023-00499-x>
- Yiying, W., & Yeze, Z. (2019). Cryptocurrency Price Analysis with Artificial Intelligence. *5th International Conference on Information Management, ICIM 2019*, 97–101. <https://doi.org/10.1109/INFOMAN.2019.8714700>